

REGRESION LINEAL MULTIPLE

El análisis de regresión lineal Múltiple tiene por objeto, hallar una relación funcional lineal entre una variable dependiente (y) y otras independientes ($x_1, x_2, x_3, \dots, x_k$).

Luego de hallar esta ecuación, se podrá **predecir**, el valor de y , conociendo los valores de $x_1, x_2, \dots, x_k$.

La ecuación buscada es de la forma:

$$y_i = \beta_0 + \beta_1 \cdot x_i + \beta_2 \cdot x_2 + \dots + \beta_k \cdot x_k$$

Luego: $y_i = \hat{y}_i + e_i$, siendo e_i el **error residual** de la observación i -ésima, que se asume con distribución normal, de media $\mu = 0$ y varianza σ^2 .

Interpretaciones:

$\hat{\beta}_0 \rightarrow$ Cuando $x_1=0, x_2=0, \dots, x_k=0$ entonces $y=\hat{\beta}_0$.

$\hat{\beta}_i \rightarrow$ Cuando x_i aumenta en una unidad, entonces y varía en promedio en $\hat{\beta}_i$ unidades.

Intervalo de confianza de los coeficientes :

$$\beta_i \in < \hat{\beta}_i \pm t_{(1-\frac{\alpha}{2}, n-k-1)} \cdot SE_{\beta_i} >$$

Donde SE_{β_i} es el error estándar del coeficiente estimado β_i .

Pruebas de hipótesis:

1) Significancia de los coeficientes:

$H_0: \beta_i = 0$ (no significativo)

$H_a: \beta_i \neq 0$ (significativo)

Se rechaza H_0 si: $|T_{\beta_i}| > t_{(1-\frac{\alpha}{2}, n-k-1)}$

Estadístico de prueba :

$$T_{\beta_i} = \frac{\hat{\beta}_i}{SE_{\beta_i}}$$

2) Prueba general de los coeficientes:

$H_0: \beta_i = b$

Posibilidades:

*Si $H_a: \beta_i > b$. $\rightarrow$ se rechaza H_0 si $\bar{T}_{\beta_i} > t_{(1-\alpha, n-k-1)}$

*Si $H_a: \beta_i < b$. $\rightarrow$ se rechaza H_0 si $\bar{T}_{\beta_i} < t_{(\alpha, n-k-1)}$

*Si $H_a: \beta_i \neq b$. $\rightarrow$ se rechaza H_0 si $|\bar{T}_{\beta_i}| > t_{(1-\frac{\alpha}{2}, n-k-1)}$

Pero ahora el estadístico de prueba es :

$$\bar{T}_{\beta_i} = \frac{\hat{\beta}_i - b}{SE_{\beta_i}}$$

3) Prueba de significancia de todo el modelo:

H_o : modelo no significativo.

H_a : modelo significativo.

Se rechaza H_o si

$$F_o > F(1 - \alpha, k, n - k - 1)$$

Estadístico de prueba:

$$F_o = \frac{CMR}{CME} = \frac{\text{cuadrado medio de regresion}}{\text{cuadrado medio del error}}$$

La tabla de coeficientes:

predictor	coef	SE coef	T	P value
cte	$\hat{\beta}_0$	SE_{β_0}	T_{β_0}	p_{β_0}
X ₁	$\hat{\beta}_1$	SE_{β_1}	T_{β_1}	p_{β_1}
X ₂	$\hat{\beta}_2$	SE_{β_2}	T_{β_2}	p_{β_2}
...				
X _k	$\hat{\beta}_k$	SE_{β_k}	T_{β_k}	p_{β_k}

La tabla de ANOVA:

fuelle	g.l.	S.C	C.M.	F	P value
regresion	k	SCR	CMR	F _o	P _{anova}
error	n- k-1	SCE	CME	—	—
total	n-1	SCT	—	—	—

SCR: suma de cuadrados de regresión

SCE: suma de cuadrados del error

SCT: suma de cuadrados del total

(SCR + SCE = SCT)

CMR: cuadrado medio de regresión

CME: cuadrado medio del error

($CMR = \frac{SCR}{k}$, $CME = \frac{SCE}{n-k-1}$)

F_o: estadístico de prueba.

($F_o = \frac{CMR}{CME}$)

Cálculo de las sumas de cuadrados:

- $SCT = \sum_{i=1}^n (y_i - \bar{y})^2$
- $SCE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$
- $SCR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$

$y_i \rightarrow$ datos observados (reales) de la var. Y

$\bar{y} = \frac{y_1 + y_2 + \dots + y_n}{n}$ → media de los observados

$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 \cdot x_i + \hat{\beta}_2 \cdot x_2 \dots + \hat{\beta}_k \cdot x_k$ → valor estimado de y_i , a partir de la ecuación

PROPIEDADES:

i) el coeficiente de determinación es denotado: $R^2 = R\text{-sq} = \frac{SCR}{SCT} \cdot 100\%$

Interpretación: el $R^2\%$ de las variaciones de Y , son explicados por las variaciones de las variables independientes del modelo.

ii) el error estándar de estimación se denota

$$S_e = \sqrt{CME}$$

iii) $T_{\beta_i} = \frac{\hat{\beta}_i}{SE_{\beta_i}}$

iv) **P valores**

de anova:

$$P_{anova} = p(F(k, n - k - 1) > F_o)$$

de la tabla de coeficientes:

$$p_{\beta_i} = 2P(T(n - k - 1) > |T_{\beta_i}|)$$